

뉴스 토픽모델링 방법론 정리

각 문단 앞의 번호로 항목을 지칭해 삭제/수정을 요청할 수 있습니다. (이전 버전은 업종별로 뉴스를 4개로 쪼개는 방식이었는데, 전면 재설계해서 이 문서도 새로 썼습니다.)

개요

1. 이 문서는 소비상권 BI 프로젝트의 C(텍스트 분석) 역할로 만든 뉴스 토픽모델링 파이프라인 (`scripts/build_news_topics.py`)이 현재 어떻게 동작하는지 정리한 것입니다. 목적은 A(매출 대시보드)에서 특정 시기에 매출이 튀거나 꺼진 걸 발견했을 때, 그 시기에 소상공인 관련 뉴스에서 어떤 이슈가 있었는지 확인할 수 있게 하는 것입니다 — 즉 이 대시보드는 독립적으로 훑어보는 화면이 아니라, 매출 데이터를 보다가 “이 시기 왜 이랬지?” 싶을 때 찾아오는 화면입니다.
2. 산출물은 세 개의 CSV입니다. `data/processed/news_topic_shares.csv` (기준월·토픽ID·토픽명·비중(%)·문서수 — 대시보드용), `data/processed/news_topic_keywords.csv` (토픽ID·상위 키워드 10개 — 라벨링용), `data/processed/news_articles_sample.csv` (기준월·토픽ID·토픽명·제목·날짜·URL — 대표 기사, 대시보드 “시기 살펴보기”용).

1. 데이터 수집

3. BigKinds Open API가 유료라 웹사이트에서 수동으로 검색·다운로드했습니다. 처음엔 업종(외식업/숙박업/서비스업/소매업)별로 4번 나눠 검색했는데, 두 가지 이유로 전면 재설계했습니다. 하나는 “업종명” 자체가 검색어로는 부정확하다는 것 — 특히 “서비스업”은 “서비스업 생산지수” 같은 거시경제 통계 용어로 흔히 쓰여서, 실측 결과 관련 기사 비율이 5.6%에 불과했습니다. 다른 하나는 더 근본적인 문제로, “특정 업종 매출이 급증한 시기의 원인 뉴스”를 찾을 때 그 뉴스에 업종명이 꼭 들어있어야 할 이유가 없다는 점입니다(예: “긴급재난지원금 지급” 뉴스는 업종명이 없어도 매출에 영향을 줌). 그래서 업종 구분 없이 “소상공인 OR 자영업” 검색어 하나로 통합했습니다.
4. 검색 결과 언론사를 “아시아경제” 한 곳으로 좁혀서 16,261건을 받았습니다. 여러 매체를 다 포함하면 지역 보도자료성 기사가 매체마다 거의 같은 내용으로 중복 보도되는 경우가 많아, 매체 하나로도 큰 흐름은 잡힌다고 판단했습니다. 다만 이건 단일 매체 편향이 있을 수 있다는 뜻이기도 합니다 — 9번 항목 참고.
5. 기간은 2021-08-23~2026-08-23(다운로드 시점 기준 5년)입니다. 실제 분석에 쓰인 기간은 기사 날짜 기준 2021-08~2026-08입니다.

2. 업종 구분을 없앤 구조

6. 이제 뉴스 토픽은 업종과 무관하게 “이 시기에 소상공인 전반에서 어떤 이슈가 있었는지”만 봅니다. 대시보드 (`streamlit_demo/pages/4_통합요약.py`)에서 사이드바 업종을 바꾸면 ①매출·③정책효과 패널은 갱신되지만, ②원인(토픽) 패널은 그대로 유지됩니다.
7. 데이터 구조에도 업종 컬럼이 없습니다 — `news_topic_shares.csv` 는 기준월·토픽ID·토픽명·비중(%)·문서수만 가집니다.

3. 전처리

8. 처음엔 “뉴스 식별자” 컬럼으로 중복 기사를 제거했는데, 16,261건 중 12,785건(78%)이 제거되는 이상한 결과가 나와서 확인해보니, 서로 완전히 다른 기사(제목이 전혀 다름)인데도 식별자 값이 같은 경우가 많았습니다 — 이 컬럼이 기사 단위 고유값이 아니었던 것으로 보입니다. (제목, 날짜) 조합으로 중복 판정 기준을 바꿨습니다.
9. 바꾼 기준으로는 실제 중복이 6건뿐이었습니다(16,261건 중). 즉 처음 발견한 “78% 중복”은 전부 오탐이었고, 실제 데이터는 훨씬 깨끗했습니다.
10. 별도의 “관련성 필터”(본문에 소상공인 관련 단어가 있는지 확인하는 단계)는 두지 않습니다 — “소상공인 OR 자영업” 검색 자체가 이미 관련성을 보장한다고 보기 때문입니다. (예전 업종별 검색 방식에서는 검색어가 부정확해서 이런 필터가 필요했지만, 지금은 필요 없습니다.)

4. 토큰화

11. 한국어 형태소 분석기 `konlpy.tag.Okt` 로 명사만 추출합니다. 1글자 단어와 “기자, 사진, 연합뉴스, 무단전재, 이날, 지난해” 같은 기사 상투어는 불용어로 걸러냅니다.
12. Okt가 “소상공인”을 “소상”+“공인”으로, “자영업자”를 “자영”+“업자”로 쪼개는 문제가 있습니다. 검색어 자체가 이 단어들을 포함해 거의 모든 문서에 등장하므로 토픽 구분에 전혀 도움이 안 되고 노이즈만 됩니다. 이것도 불용어에 추가해 제거했습니다.

5. LDA 토픽모델링 원리

13. LDA(Latent Dirichlet Allocation)는 “문서 하나는 여러 토픽이 섞인 것이고, 토픽 하나는 특정 단어들이 자주 같이 나오는 패턴이다”라는 가정으로 동작합니다. 알고리즘은 “정치”, “코로나” 같은 의미를 전혀 모르고, 어떤 단어들이 같은 문서에 자주 같이 등장하는지 통계적으로 찾아낼 뿐입니다.
14. 입력은 `sklearn.feature_extraction.text.CountVectorizer` 로 만든 “문서×단어 등장 횟수” 행렬입니다. `min_df=2` (2건 미만 등장 단어 제외), `max_df=0.6` (문서의 60% 넘게 등장하는 단어 제외)를 적용했습니다.
15. `sklearn.decomposition.LatentDirichletAllocation` 으로 모델을 학습시킵니다. 토픽 개수 (`n_components`)는 사람이 미리 정해야 하는 값입니다 — 알고리즘이 스스로 정하지 않습니다. `random_state=42` 로 고정해 같은 데이터면 항상 같은 결과가 나오게 했고, `max_iter=20` 으로 반복 횟수를 정했습니다.
16. 결과물은 두 가지입니다. `lda.components_` 는 토픽별로 각 단어가 그 토픽을 얼마나 대표하는지 점수(여기서 상위 10개를 뽑은 게 `news_topic_keywords.csv`), `doc_topic (= lda.fit_transform(X))` 은 문서마다 “토픽0일 확률 0.xx, 토픽1일 확률 0.xx…” 값입니다. 이 `doc_topic` 이 월별 비중(%) 계산과 대표 기사 선정(20번 항목)의 원재료입니다.

17. 토픽 개수는 4, 6, 8, 9, 10, 11, 12, 16개로 직접 돌려보며 정했습니다. 8개까지는 전부 뚜렷하게 구분됐고, 12개까지도 대체로 괜찮았지만(오히려 “재해·재난 긴급지원”, “청년일자리” 같은 새 결이 드러남), 16개부터는 “중소기업·정책 간담회”와 “중소기업중앙회·규제”처럼 사실상 같은 내용의 토픽이 중복으로 쪼개지기 시작했습니다.

18. 최종적으로 9개를 선택했습니다. “재해·재난 긴급지원” 토픽은 9개부터 뚜렷하게 나타났고, “청년일자리”(청년+일자리 키워드가 같이 묶이는 것)는 11개는 돼야 나타났는데, 안정성과 새 주제 포착 사이에서 9개를 1차 기준으로 잡았습니다. 표본이 더 늘어나면 11~12개로 재조정을 고려할 수 있습니다.

6. 라벨링과 검증

19. LDA는 “토픽0”, “토픽1”처럼 번호만 줄 뿐 이름을 붙이지 않습니다. 상위 키워드 10개를 사람이 읽고 의미를 판단해 `scripts/build_news_topics.py` 의 `토픽_라벨` 디렉터리에 직접 채웠습니다.

20. 라벨이 실제 기사와 맞는지 확인하기 위해, 토픽별로 `doc_topic` 확률이 가장 높은 대표 기사 제목을 뽑아 검증했습니다(`doc_topic[:,k].argsort()` 로 내림차순 정렬). 9개 토픽 모두 대표 기사가 라벨과 일관되게 맞아떨어지는 것을 확인했습니다.

21. 최종 9개 토픽과 대표 키워드:

토픽명	대표 키워드
정치·정당 동향	금융, 국민, 경제, 민주당, 후보, 위원회, 정부, 대통령
코로나 민생대책	경제, 코로나, 민생, 정부, 회복, 대책, 회의, 안정
지역축제·행사	청장, 축제, 개최, 서울, 행사, 시민, 지역, 동행
정부 예산·중소기업 지원정책	정부, 예산, 벤처기업, 중소, 추경, 지원, 장관
지역화폐·소비쿠폰	상품권, 소비, 사랑, 배달, 발행, 할인, 카드, 매출
재해·재난 긴급지원	피해, 중소기업, 지원, 현장, 경기도, 중앙회, 재난, 보험
골목상권·전통시장 활성화	지역, 시장, 광주, 전통, 사업, 상권, 활성화, 선정
자금·금리 지원	지원, 사업, 대상, 자금, 신청, 지급, 금리, 원금
금융기관 협약·보증지원	지원, 금융, 은행, 보증, 협약, 신용, 업무

7. 월/분기 집계 구조

22. 원본은 월 단위로만 저장합니다(`기준월` 컬럼). 분기·반기 등 더 넓은 단위는 대시보드에서 그때그때 즉석으로 묶습니다.

23. 이게 가능한 이유는 수학적으로 정확히 맞아떨어지기 때문입니다 — LDA는 문서마다 토픽 확률의 합이 1이 되게 계산하므로, 월별 비중(%)을 그 달의 문서수로 가중평균하면 분기 단위로 처음부터 다시 계산했을 때와 정확히 같은 값이 나옵니다. `streamlit_demo/common.py`의 `_aggregate_topics()`가 이 가중평균을 수행하며, 실제로 각 분기별 합이 정확히 100%로 검증했습니다.

8. 대시보드 UX 설계

24. `streamlit_demo/pages/2_토픽모델링.py`은 “매출 대시보드에서 궁금했던 시기를 골라 그때 무슨 뉴스가 있었는지 확인한다”는 목적에 맞게 설계했습니다. 상단에 월/분기 표시 단위 토글, 전체 흐름을 보여주는 추이 그래프가 있고, 그 아래 “🔍 시기 살펴보기” 섹션이 핵심입니다.

25. “시기 살펴보기”는 슬라이더로 특정 월/분기를 고르면 ① 그 시기 토픽 비중, ② 직전 시기 대비 증감(가로 diverging bar — 어느 토픽이 갑자기 튀었는지 한눈에 보임), ③ 대표 기사 목록(제목·날짜·클릭 가능한 원문 링크, 토픽으로 추가 필터링 가능)을 같이 보여줍니다. 대표 기사는 19번 항목의 `doc_topic` 확률 기준 상위 5개씩(월×토픽 조합당)을 미리 뽑아 `news_articles_sample.csv`로 저장해둔 것입니다.

26. `4_통합요약.py`의 “②원인” 패널에도 최근분기 최다 토픽의 대표 기사 링크 1개를 붙여, 요약 화면에서 바로 원문까지 갈 수 있게 했습니다.

9. 한계

27. 가장 큰 한계는 단일 매체(아시아경제) 편향입니다. 이 매체가 특별히 많이 다루는 주제(예: 지자체 지원정책, 지역 보도자료성 기사)가 실제로보다 과대표될 수 있습니다.

28. 토픽 라벨은 사람이 키워드 10개와 대표 기사 몇 개만 보고 판단한 것이라 주관이 개입돼 있습니다. 정량적인 검증(예: 사람이 직접 라벨링한 샘플과의 일치도 측정)은 하지 않았습니다.

29. 표본(16,255건)은 충분히 크지만, 그래도 초기(2021년 하반기)처럼 문서수가 상대적으로 적은 달은 비중(%) 추정치가 더 불안정할 수 있습니다. `news_topic_shares.csv`의 “문서수” 컬럼으로 이런 달을 걸러낼 수 있습니다.

10. 향후 개선

30. 매체 다양화 — 아시아경제 외 다른 매체도 추가로 받아서 편향을 줄일 수 있습니다(다만 서두에 말한 “중복 보도” 문제 때문에 효과가 제한적일 수 있음 — 실제로 얼마나 다른 내용이 늘어나는지 확인 필요).

31. 토픽 개수를 표본이 더 늘어난 뒤 11~12개로 재조정하는 것을 고려할 수 있습니다(“재해지원”은 9개부터, “청년일자리”는 11개부터 뚜렷해짐 — 17·18번 항목 참고).

32. 대표 기사가 실제로 그 시기의 “원인”인지는 사람이 최종 판단해야 합니다 — 이 대시보드는 후보 뉴스를 빠르게 찾아주는 도구이지, 인과관계를 자동으로 증명해주지 않습니다.